Mini Project 01 - IMDB web scraping

```
library(tidyverse)
library(rvest) # scrape data from interne
url <- "https://www.imdb.com/search/title/?groups=top_100&sort=user_rating,desc"</pre>
print(url)
[1] "https://www.imdb.com/search/title/?groups=top_100&sort=user_rating,desc"
imdb <- read_html(url)</pre>
# movie title
# html_text2() delete special
titles <- imdb %>%
    html_nodes("h3.lister-item-header") %>%
    html_text2()
ratings <- imdb %>%
    html_nodes("div.ratings-imdb-rating") %>%
```

html_text2()
as.numeric

.Primitive("as.double")

```
rating

'9.3' \cdot '9.2' \cdot '9.0' \cdot '9.0' \cdot '9.0' \cdot '9.0' \cdot '8.9' \cdot '8.8' \cdot '8.5' \cdo
```

```
# nember of vote
num_votes <- imdb %>%
  html_nodes("p.sort-num_votes-visible") %>%
  html_text2()
```

```
#build a data set

df <- data.frame(
    title = titles,
    rating = ratings,
    num_vote = num_votes
)

head(df)</pre>
```

A data.frame: 6×3

	عاداء		
	title	rating	num_vote
	<chr></chr>	<chr></chr>	<chr></chr>
1	1. The Shawshank Redemption (1994)	9.3	Votes: 2,680,677 Gross: \$28.34M Top 250: #1
2	2. The Godfather (1972)	9.2	Votes: 1,858,473 Gross: \$134.97M Top 250: #2
3	3. The Dark Knight (2008)	9.0	Votes: 2,653,998 Gross: \$534.86M Top 250: #3
4	4. The Lord of the Rings: The Return of the King (2003)	9.0	Votes: 1,847,287 Gross: \$377.85M Top 250: #7
5	5. The Godfather Part II (1974)	9.0	Votes: 1,272,091 Gross: \$57.30M Top 250: #4
6	6. Schindler's List (1993)	9.0	Votes: 1,356,477 Gross: \$96.90M Top 250: #6

```
library(tidyverse)
library(rvest)
Warning message in system("timedatectl", intern = TRUE):
"running command 'timedatectl' had status 1"
Warning message:
"Failed to locate timezone database"
— Attaching packages —
                                                       - tidyverse 1.3.1
√ ggplot2 3.3.5
                 ✓ purrr 0.3.4
— Conflicts —
                                                 - tidyverse_conflicts()
X dplyr::filter() masks stats::filter()
x purrr::flatten() masks jsonlite::flatten()
X dplyr::lag() masks stats::lag()
Attaching package: 'rvest'
```

```
url <- read_html("https://specphone.com/Samsung-Galaxy-A04.html")
```

```
att <- url %>%
   html_nodes("div.topic") %>%
   html_text2()

value <- url %>%
   html_nodes("div.detail") %>%
   html_text2()
```

```
data.frame(Atrribuute = att, value)
```

A data.frame: 31×2

Atrribuute	value		
<chr></chr>	<chr></chr>		
วันเปิดตัว	ตุลาคม 2565		
วันวางจำหน่าย	ยังไม่วางจำหน่าย		
ขนาด	164.40 x 76.30 x 9.10 มม.		
น้ำหนัก	192 กรัม		
วัสดุ	Glass front, plastic back, plastic frame		
SIM	รองรับ 2 ชิมการ์ด (nano sim, nano sim)		
Technology	HSPA 42.2/5.76 Mbps, LTE-A		
2G	850/900/1800/1900		
3G	850/900/1900/2100		
4G	850/900/1900/2100/2600		
5G	-		
ความเร็ว	HSPA 42.2/5.76 Mbps, LTE-A		
ประเภท	PLS LCD		
ขนาดหน้าจอ	6.50 นิ้ว		
ความละเอียด	720 x 1600 pixels		
ระบบปฏิบัติการ	Android 12		
ชิปประมวลผล	Spreadtrum Unisoc SC9863A 1.6 GHz		
ชิปกราฟิก	PowerVR GE8322		
หน่วยความจำ	3 GB		
ความจุ	32 GB		
Memory Card	microSD (1)		
กล้องหลัก	ตัวที่ 1: 50 MP, f/1.8, (wide), AF ตัวที่ 2: 2 MP, f/2.4, (depth)		
ความละเอียดวีดีโอ	1080p@30fps		
กล้องหน้า	ตัวที่ 1: 5 MP, f/2.2		
Bluetooth	5.0, A2DP, LE		
Wi-Fi	802.11 a/b/g/n/ac, dual-b		
USB	Type-C		
GPS	GLONASS, GALILEO, BDS		
NFC	ไม่รองรับ		
ความจุ	5,000 mAh		
ประเภท	Non-removable Li-Po Batt		

samsung_url <- read_html("https://specphone.com/brand/Samsung")</pre>

```
# link samsung all samsung smartphone
links <- samsung_url %>%
  html_nodes("li.mobile-brand-item a") %>%
  html_attr("href")
```

```
#increase http specphone.com
full_links <- paste0("https://specphone.com", links)</pre>
```

```
full_links[1:10]
```

```
'https://specphone.com/Samsung-Galaxy-M13.html' · 'https://specphone.com/Samsung-Galaxy-A23.html' ·
```

```
result <- data.frame()
for ( link in full_links[1:5]){
    ss_topic <- link %>%
        read_html() %>%
        html_nodes("div.topic") %>%
        html_text2()

ss_detail <- link %>%
        read_html() %>%
        html_nodes("div.detail") %>%
        html_nodes("div.detail") %>%
        html_text2()

    tmp <- data.frame(ss_topic, ss_detail )
        result <- bind_rows(result, tmp)
        print("Progess ...")

}
print(head(result),3)</pre>
```

```
[1] "Progess ..."
```

 $[&]quot;https://specphone.com/Samsung-Galaxy-A13.html" \cdot "https://specphone.com/Samsung-Galaxy-M32-5G.html" \cdot "https://specphone.com/Samsung-Ga$

^{&#}x27;https://specphone.com/Samsung-Galaxy-A12-Nacho.html' ·

^{&#}x27;https://specphone.com/Samsung-Galaxy-Pocket-Neo.html' ·

^{&#}x27;https://specphone.com/Samsung-Galaxy-Young.html' · 'https://specphone.com/Samsung-Galaxy-J1-Mini.html' ·

^{&#}x27;https://specphone.com/Samsung-Galaxy-A01-Core-1-16GB.html' ·

^{&#}x27;https://specphone.com/Samsung-Galaxy-V-PLUS.html'

^{[1] &}quot;Progess ..."

```
[1] "Progess ..."
[1] "Progess ..."
[1] "Progess ..."
     ss_topic
                                                  ss_detail
1
      วันเปิดตัว
                                               มิถุนายน 2565
2 วันวางจำหน่าย
                                             ยังไม่วางจำหน่าย
                                165.40 x 76.90 x 8.40 มม.
4
         น้ำหนัก
                                                     192 กรัม
5
           วัสดุ Glass front, plastic back, plastic frame
6
           SIM
                     รองรับ 2 ซิมการ์ด (nano sim, nano sim)
```

```
#write csv
write_csv(result, "result_ss_phone.csv")
```